

Assignment_10_written

1

1. Consider a forward SDE

$$dx_t = f(x_t, t) dt + g(x_t, t) dW_t,$$

show that the corresponding probability flow ODE is written as

$$dx_t = \left[f(x_t, t) - \frac{1}{2} \frac{\partial}{\partial x} g^2(x_t, t) - \frac{g^2(x_t, t)}{2} \frac{\partial}{\partial x} \log p(x_t, t) \right] dt.$$

0. Definition and symbol

- Ito Process (Forward SDE) :

$$dx_t = f(x_t, t)dt + g(x_t, t)dW_t$$

where W_t is standard Brownian motion ;

f is drift, g is diffusion magnitude.

- let $p(x, t)$ be the PDF of x_t . Assume $p(x, t)$ is smooth and decays sufficiently fast as $x \rightarrow \pm\infty$ so that boundary terms vanish under integration by parts.
- Assume f, g and needed derivatives are smooth enough to justify exchanging expectation and differentiation, and to apply integration by parts.

1. Meaning of the forward SDE and the FP equation

1.1 Forward SDE

- $f(x_t, t)dt$: drift term.
- $g(x_t, t)dW_t$: diffusion term.
- In **Ito calculus**: $dW_t \sim \mathcal{N}(0, dt)$, $(dW_t)^2 = dt$.

1.2 Fokker-Planck equation

The density $p(x, t)$ corresponding to the SDE satisfies

$$\boxed{\frac{\partial p}{\partial t} = -\frac{\partial}{\partial x}(fp) + \frac{1}{2} \frac{\partial^2}{\partial x^2}(g^2 p)} \quad (\text{FP})$$

1.3 Conservation

Any deterministic flow $v(x, t)$ induces a density evolution

$$\boxed{\frac{\partial p}{\partial t} = -\frac{\partial}{\partial x}(v(x, t)p(x, t))} \quad (\text{CE})$$

2. Rewriting FP into continuity form and identifying $v(x, t)$

Start from (FP):

$$\frac{\partial p}{\partial t} = -\frac{\partial}{\partial x}(fp) + \frac{1}{2} \frac{\partial^2}{\partial x^2}(g^2 p)$$

Expand the second-derivative term as a single first derivative:

$$\frac{\partial^2}{\partial x^2}(g^2 p) = \frac{\partial}{\partial x} \left(\frac{\partial}{\partial x}(g^2 p) \right) = \frac{\partial}{\partial x} \left(p \frac{\partial g^2}{\partial x} + g^2 \frac{\partial p}{\partial x} \right)$$

Substitute back into (FP):

$$\frac{\partial p}{\partial t} = -\frac{\partial}{\partial x}(fp) + \frac{1}{2} \frac{\partial}{\partial x} \left(p \frac{\partial g^2}{\partial x} + g^2 \frac{\partial p}{\partial x} \right)$$

Collect the right-hand side into a single ∂_x :

$$\frac{\partial p}{\partial t} = -\frac{\partial}{\partial x} \left[fp - \frac{1}{2} p \partial_x g^2 - \frac{1}{2} g^2 \partial_x p \right] \quad (\star)$$

Use $\partial_x p = p \partial_x \log p$ to rewrite:

$$\frac{1}{2} g^2 \partial_x p = \frac{1}{2} g^2 p \partial_x \log p$$

Then (\star) becomes

$$\boxed{\frac{\partial p}{\partial t} = -\frac{\partial}{\partial x} \left([f - \frac{1}{2} \partial_x g^2 - \frac{1}{2} g^2 \partial_x \log p] p \right)} \quad (\star\star)$$

Comparing $(\star\star)$ with CE, we identify the velocity field:

$$\boxed{v(x, t) = f(x, t) - \frac{1}{2} \partial_x (g^2(x, t)) - \frac{g^2(x, t)}{2} \partial_x \log p(x, t)} \quad (*)$$

Therefore, the associated Probability-Flow ODE (PF-ODE) is

$$dx_t = v(x_t, t)dt = \left[f(x_t, t) - \frac{1}{2} \partial_x g^2(x_t, t) - \frac{g^2(x_t, t)}{2} \partial_x \log p(x_t, t) \right] dt$$

2

2. AI 的未來與機器學習的基石

請以 1-2 頁 (約 600-800 字) 為限。

...

1. AI 的未來能力

請具體描述一件你認為目前 AI 無法做到，但 20 年後有可能做到的重要事情。

- 這件事應該是「你認為對人類、社會、科學或文化具有重大意義」的。
- 請具體描述該能力的內容與應用場景 (例如「自動發現新的物理定律」、「全自動醫學診斷並能解釋理由」等) 。
- 盡量避免空泛描述 (如「AI 會更聰明」)，而要明確指出「做什麼」、「為什麼重要」。

2. 涉及的機器學習類型

根據你對問題一的構想，判斷該能力的實現主要涉及哪一類機器學習方法：

- 監督式學習 (Supervised Learning)
 - 非監督式學習 (Unsupervised Learning)
 - 強化學習 (Reinforcement Learning)
- 或是以上幾者的組合。

請簡述你的理由：

複製

- 為什麼需要這類學習？
- 該任務中的「資料來源」與「目標訊號」分別是什麼？
- 是否存在學習回饋或環境互動？

3. 第一步的「模型化」

假設要讓 AI 在 20 年後達到問題一的能力，請思考並設計出能夠作為第一個研究步驟的「簡化模型問題 (model problem)」。

說明以下幾點：

- 這個簡化問題在概念上如何代表你理想中的最終能力？
- 它的可測試性 (你如何知道模型是否成功？)
- 需要哪些數學或機器學習工具來解決？

數學證明

我認為在未來二十年內，AI 可能夠在「數學證明」這一傳統上被視為人類專屬的高層次思維領域中取得突破。

目前，大多數 AI 系統可以透過大型語言模型 (LLMs) 或自動定理證明器 (ATPs) 生成部分正確的推理步驟，但它們仍受限於搜尋空間過大與邏輯不完備的問題。

未來的 AI 若結合符號推理 (symbolic reasoning) 與深度學習 (deep neural networks) , 可在「自動探索新證明策略」上發揮潛力。

如DeepMind 的 AlphaGeometry (2023) 成功利用類神經結構搜尋幾何定理證明, 顯示透過 search tree expansion與neural guidance, AI 能夠以接近人類敘述的方式以及思考的技巧發現數學結構中的關聯。

若要讓 AI 在數學領域達到這樣的能力, 強化學習 (Reinforcement Learning, RL) 會扮演主要角色。

在證明過程中, 每一個「推理步驟」都可視為一個動作 (action) , 而「達成完整正確證明」即為最終回饋 (reward) 。

這樣的架構與圍棋相似, 差別在於數學推理的狀態空間 (state space) 更加龐大且非平滑, 如過去的Alpha Go就是個典型的例子。

若要讓搜尋更高效, AI 需要透過策略優化 (policy optimization) 改進策略函數, 讓 AI 能選出有邏輯意義的步驟;

同時利用價值函數近似 (value function approximation) 預測哪些路徑更接近正確解;

並加入損失函數正則化 (loss function regularization) 以控制模型偏誤, 避免幻覺式推理 (hallucinated reasoning) 發生。

(內容優化by gpt)

要讓 AI 具備可驗證的證明能力, 第一步是將人類的自然語言表述轉換成形式化的邏輯結構。

這種過程稱為自然語言到符號邏輯轉換, 目前已有如 GPT-f (OpenAI, 2020) 與 LeanDojo (MIT, 2023) 等系統嘗試讓模型理解並重現人類數學家在 Lean 定理證明器中的推理過程。

未來的研究可將數學問題依結構分類, 讓不同子模型專精處理不同類型的證明:

幾何問題以代數化 (algebraization) 方式處理, 如利用符號張量或群論結構;

代數或組合問題則可透過神經符號混合模型 (neuro-symbolic models) 進行高階抽象推理。

參考文獻:

DeepMind (2023). AlphaGeometry: An AI system for mathematical reasoning via neural search.

Polu et al. (2020). GPT-f: Automated theorem proving with large language models.

Yang et al. (2024). Deep Reinforcement Symbolic Reasoning for Formal Proof Search. arXiv:2403.01312.

Han et al. (2023). LeanDojo: Theorem proving with language models via formal verification. arXiv:2306.09264.

3. Unanswered Question

在Ito's lemma 中，如果把隨機過程 x_t 定義在彎曲空間（例如流形或非歐幾里得空間）上，Ito's lemma 的形式還能保持一樣嗎？